



单位代码 10006

学 号 22373311

分 类 号 TP311

北京航空航天大学
BEIHANG UNIVERSITY

毕业设计 (论文)

基于 EDA 工具反馈的 LLM Verilog
生成与自动优化

学 院 名 称 计算机学院

专 业 名 称 计算机科学与技术

学 生 姓 名 张金涛

指 导 教 师 王锐

2026 年 5 月

北京航空航天大学

本科生毕业设计（论文）任务书

I、毕业设计（论文）题目：

基于 EDA 工具反馈的 LLM Verilog 生成与自动优化

II、毕业设计（论文）使用的原始资料（数据）及设计技术要求：

1. AutoChip 原论文

2. VerilogEval、RTLLM 评估基准

3. Icarus Verilog 开源 EDA 工具

4. 大语言模型 API（Claude、GPT 系列）

5. 北航本科毕业设计相关规范

III、毕业设计（论文）工作内容：

1. 复现 AutoChip 风格 RTL 代码生成与反馈修复系统

2. 接入 VerilogEval 和 RTLLM 双 benchmark

3. 在三个不同能力等级的 LLM 上验证反馈循环有效性

4. 通过消融实验分离反馈信息与多采样的贡献

5. 探索反馈粒度、多轮对话和提示词策略的影响

6. 建立实验产物管理与审计机制

IV、主要参考资料：

- [1] Thakur S, et al. AutoChip: Automating HDL Generation, 2023
- [2] Liu M, et al. VerilogEval: Evaluating LLMs for Verilog, ICCAD 2023
- [3] Lu Y, et al. RTLLM: Open-Source Benchmark for RTL Generation, 2024
- [4] Liu S, et al. RTLCoder: LLM-Assisted RTL Code Generation, 2024
- [5] Tsai Y, et al. RTLFixer: Fixing RTL Syntax Errors with LLMs, 2024
- [6] Yao Z, et al. HDLDebugger: Streamlining HDL Debugging, 2025
- [7] Wei J, et al. Chain-of-Thought Prompting, NeurIPS 2022
- [8] Brown T, et al. Language Models are Few-Shot Learners, NeurIPS 2020

____ 计算机 ____ 学院 ____ 计算机科学与技术 ____ 专业类 ____ 220611 ____ 班

学生 ____ 张金涛 ____

毕业设计(论文)时间： ____ 2025 ____ 年 ____ 12 ____ 月 ____ 29 ____ 日至 ____ 2026 ____ 年 ____ 5 ____ 月 ____ 22 ____ 日

答辩时间： ____ 2026 ____ 年 ____ 6 ____ 月 ____ 3 ____ 日

成 绩： ____

指导教师： ____

兼职教师或答疑教师（并指出所负责部分）：

____ 系（教研室）主任（签字）： ____

注：任务书应该附在已完成的毕业设计（论文）的首页。



本人声明

我声明，本论文及其研究工作是由本人在导师指导下独立完成的，在完成论文时所利用的一切资料均已在参考文献中列出。

作者： 张金涛

签字：

时间： 2026 年 5 月



基于 EDA 工具反馈的 LLM Verilog 生成与自动优化

学 生：张金涛

指导教师：王锐

摘 要

集成电路设计复杂度的持续提升使得寄存器传输级（RTL）代码的编写和验证日益耗时。大语言模型在代码生成领域展现出了一定能力，但 RTL 代码不同于普通软件——它描述的是并行执行的硬件结构，不仅要求语法正确，还必须通过 EDA 工具的编译和仿真验证。实际使用中，模型在零样本条件下生成的 Verilog 代码常存在语法错误、接口不匹配和时序逻辑错误等问题，在复杂设计任务上正确率有限。

针对上述问题，本文构建了一个 AutoChip 风格的 RTL 自动生成与反馈修复原型系统，实现了“生成—编译—仿真—反馈—修复”的完整迭代闭环。系统支持 VerilogEval-Human 和 RTLLM 双 benchmark 接入，通过统一 API 网关实现多模型切换，并支持可配置的反馈粒度、多轮对话反馈和多种提示词策略。

在实验方面，本文设计并执行了七组递进式实验。在 VerilogEval-Human 20 题子集上，Haiku 模型的通过率从 80%（零样本）提升至 90%（反馈）。在更具挑战性的 RTLLM_STUDY_12 上，GPT-5.4 的通过率从 50% 提升至 83%。消融实验表明反馈信息本身贡献了约 57% 的提升，多采样贡献约 43%，且存在仅反馈可解而多次独立重试无法通过的设计题目。

稳定性实验（每模型 4 轮重复）确认了核心结论的统计稳健性。反馈粒度实验揭示了倒 U 型趋势——编译反馈和简洁反馈是最稳健的选择，过于丰富的反馈可能导致信息过载。实验还发现反馈效果存在模型依赖性，不同模型对反馈信息的利用能力存在差异。

本文的研究表明，EDA 工具反馈循环对大语言模型的 RTL 代码生成具有实际价值，但反馈策略需要结合模型能力、任务难度和反馈粒度进行综合设计。

关键词：大语言模型；Verilog 代码生成；EDA 工具反馈；自动优化；RTLLM



LLM Verilog Generation and Automatic Optimization Based on EDA Tool Feedback

Author: Zhang Jintao

Tutor: Wang Rui

Abstract

As integrated circuit design complexity continues to grow, writing and verifying Register Transfer Level (RTL) code has become one of the most time-consuming stages in chip design. Large Language Models (LLMs) show potential in code generation, yet RTL code fundamentally differs from conventional software — it describes parallel hardware structures and must pass compilation and simulation verification by Electronic Design Automation (EDA) tools. In practice, Verilog code generated under zero-shot conditions frequently contains syntax errors, interface mismatches, and timing logic errors, particularly for complex designs.

This thesis builds an AutoChip-style prototype for automatic RTL generation and feedback-driven repair. The system supports dual benchmarks (VerilogEval-Human and RTLLM), multi-model switching, configurable feedback granularity, multi-turn feedback, and multiple prompt strategies.

Seven experiments were designed. On VerilogEval-Human, Haiku's pass rate improved from 80% to 90%. On the more challenging RTLLM_STUDY_12, GPT-5.4 improved from 50% to 83%. Ablation experiments showed that error feedback contributed about 57% of the improvement, with multiple sampling contributing about 43%.

Stability experiments (4 repetitions per model) confirmed the statistical robustness of core conclusions. Feedback granularity experiments revealed an inverted-U trend — compile-only and succinct feedback proved most robust, while excessively rich feedback may cause information overload.

This research demonstrates that EDA tool feedback loops provide practical value for LLM-based RTL generation, but feedback strategies should be designed considering model capability, task difficulty, and feedback granularity.



Key words: Large Language Models; Verilog Generation; EDA Tool Feedback; Automatic Optimization; RTLLM



目 录

1 绪论	5
1.1 研究背景与意义	5
1.2 国内外研究现状	5
1.2.1 LLM 辅助 RTL 代码生成	5
1.2.2 EDA 工具反馈与自动修复	6
1.2.3 现有工作的不足	6
1.3 本文研究内容	6
1.4 本文主要贡献	7
1.5 论文组织结构	7
2 相关技术与研究基础	8
2.1 Verilog 与 RTL 设计基础	8
2.1.1 RTL 设计的基本概念	8
2.1.2 RTL 代码与软件代码的关键差异	8
2.2 大语言模型代码生成基础	9
2.2.1 基于提示词的代码生成	9
2.2.2 LLM 生成 RTL 代码的常见问题	9
2.3 EDA 编译与仿真验证流程	9
2.3.1 编译验证	9
2.3.2 功能仿真	10
2.3.3 编译仿真反馈的信号价值	10
2.4 AutoChip 方法与 EDA Feedback Loop	10
2.4.1 AutoChip 的核心思想	10
2.4.2 反馈信息的组织	10
2.4.3 多候选生成与全局最优追踪	11
2.4.4 本文与 AutoChip 的关系	11



2.5 RTL 生成评估基准	11
2.5.1 VerilogEval Benchmark	11
2.5.2 RTLLM Benchmark	11
2.6 相关研究与本文定位	12
2.6.1 相关研究方向	12
2.6.2 本文定位	12
2.7 本章小结	12
3 系统设计与实现	13
3.1 系统总体架构	13
3.1.1 设计目标	13
3.1.2 模块划分	13
3.2 任务加载与 Benchmark 接入	14
3.2.1 Task 数据结构	14
3.2.2 VerilogEval-Human 加载器	14
3.2.3 RTLLM 加载器	14
3.2.4 适配层的必要性	15
3.3 大语言模型调用与模型管理	15
3.3.1 统一 API 网关架构	15
3.3.2 重试机制与错误分类	15
3.3.3 对实验可追溯性的意义	15
3.4 Verilog 代码提取、编译与仿真执行	15
3.4.1 代码提取	15
3.4.2 编译执行	15
3.4.3 仿真执行与结果解析	16
3.4.4 评分机制	16
3.5 反馈循环控制机制	16
3.5.1 单轮反馈循环	16
3.5.2 Zero-shot 作为退化形式	18



3.5.3 Retry-only 模式	18
3.5.4 API 错误处理	18
3.6 反馈策略扩展实现	18
3.6.1 反馈粒度级别	18
3.6.2 多轮对话反馈	18
3.7 提示词策略扩展实现	19
3.7.1 四种提示策略	19
3.7.2 数据泄漏防护	19
3.7.3 策略调度机制	19
3.8 实验产物管理与审计机制	19
3.8.1 实验目录结构	19
3.8.2 元数据与 Git 集成	19
3.8.3 审计脚本	19
3.8.4 权威实验索引	20
3.9 本章小结	20
4 实验设计	21
4.1 实验目标与总体设计	21
4.2 评估基准与任务子集	22
4.3 模型与参数设置	22
4.4 实验条件与对照设计	24
4.5 评价指标与统计方法	24
4.6 实验可靠性控制	24
4.7 本章小结	25
5 实验结果与分析	26
5.1 VerilogEval-Human 基线实验	26
5.2 RTLLM_STUDY_12 正式实验结果	27
5.3 Feedback vs Retry-only 消融实验	29
5.4 稳定性重复实验	29



5.5 反馈粒度实验	31
5.6 多轮对话反馈实验	33
5.7 提示词策略实验	33
5.8 典型案例分析	36
5.9 综合讨论	36
5.10 本章小结	38
6 总结与展望	39
6.1 本文工作总结	39
6.2 主要实验结论	39
6.3 系统局限性	40
6.4 后续工作展望	40
6.5 本章小结	41
结论	42
致谢	43
参考文献	44
附录 A 实验配置与运行命令	46
A.1 正式实验运行命令	46
A.2 环境配置	47
A.3 核心代码模块索引	47



1 绪论

1.1 研究背景与意义

随着集成电路设计规模的持续增长，寄存器传输级（RTL）代码的编写和验证已成为芯片设计流程中最耗时的环节之一。传统的 RTL 开发高度依赖工程师的专业经验——设计者需要根据功能规格手工编写 Verilog 或 VHDL 代码，并通过反复的编译、仿真和调试迭代来确保功能正确性。这一过程周期长、人力成本高，且容易因疏忽引入难以发现的逻辑错误。

近年来，大语言模型（Large Language Model, LLM）在软件代码生成领域展现出一定能力，能够根据自然语言描述生成多种编程语言的代码。这一进展自然引出了一个研究问题：大语言模型能否有效地生成硬件描述语言代码，从而辅助甚至部分替代人工的 RTL 开发过程？

然而，RTL 代码生成与普通软件代码生成存在本质差异。RTL 代码描述的是并行执行的硬件结构而非顺序执行的软件逻辑，正确的 RTL 设计不仅要求语法正确，还必须满足时序约束、位宽匹配、时钟域一致性等硬件特有要求，并通过 EDA 工具的编译和仿真验证。在零样本条件下，大语言模型生成的 RTL 代码往往存在编译错误、接口不匹配、边界条件遗漏等问题，尤其在涉及复杂状态机或浮点运算等场景时正确率较低。

这一现实使得将大语言模型的生成能力与 EDA 工具的验证能力相结合成为一个值得探索的方向。通过构建“生成—编译—仿真—反馈—修复”的迭代闭环，EDA 工具的编译和仿真输出可以作为结构化的反馈信号引导模型定向修复代码错误，有望提升 RTL 代码的自动生成质量。

1.2 国内外研究现状

1.2.1 LLM 辅助 RTL 代码生成

已有研究探索了使用大语言模型从自然语言规格直接生成 Verilog 代码的可行性 [1-2]。在评估基准方面，NVlabs 发布的 VerilogEval[3] 提供了标准化的 spec-to-RTL 评估框架，香港科技大学发布的 RTLLM[4] 则提供了更高难度的设计任务集。这些基准的建立推动了 RTL 生成方法的标准化评估和横向比较。



现有研究表明,大语言模型在简单的组合逻辑和常见时序电路上具备一定的生成能力,但在涉及复杂算法、多状态 FSM 或精确位操作的设计上,单次生成的正确率仍有较大提升空间。

1.2.2 EDA 工具反馈与自动修复

AutoChip[5]等工作提出了利用 EDA 工具反馈驱动代码修复的方法,将传统的单次生成扩展为迭代修复过程。该类方法的核心思想是将编译器和仿真器输出的错误信息提取为结构化反馈,使模型能够进行定向修复而非盲目重新生成。RTLFixer[6]针对编译错误修复进行了专门探索,HDLLDebugger[7]引入了检索增强技术辅助调试,这些研究共同体现了“验证反馈驱动修复”的研究趋势。

1.2.3 现有工作的不足

尽管上述研究在方法探索和概念验证方面取得了有价值的进展,仍有几个方面值得进一步分析。

在反馈收益的来源方面,反馈循环带来的通过率提升中有多少来自错误信息的引导、有多少仅来自多次重试的采样收益,现有工作较少对此进行严格的消融分析。在强模型与高难度场景方面,部分研究基于较早的模型或较简单的 benchmark 进行评估,需要新的实验证据。在反馈机制的影响因素方面,反馈粒度、反馈组织方式和初始提示词策略等维度对修复效果的影响,尚未得到系统的实验研究。此外,部分工作在实验结果管理和结论稳定性验证方面的机制不够完善。

1.3 本文研究内容

针对上述不足,本文的工作分为系统构建和实验研究两个层面。

在系统层面,构建了一个 AutoChip 风格的 RTL 自动生成与反馈修复原型系统,实现了完整的“生成—编译—仿真—反馈—修复”闭环,支持 VerilogEval 和 RTLLM 双 benchmark 适配、多模型统一调用、多粒度反馈构建和多种提示词策略。同时对 RTLLM 2.0 的 50 个设计进行了 Icarus Verilog 兼容性审计(41/50 完全可用),从中精选 12 道高难度设计构成 RTLLM_STUDY_12 正式研究子集。

在实验层面,使用 Haiku、Sonnet 4.6 和 GPT-5.4 三个不同能力等级的模型,进行了七组递进式实验:零样本与反馈对比实验验证基础有效性;retry-only 消融实验分离多采



样与反馈信息的贡献；每模型 4 轮的稳定性重复实验检验结论可靠性；五级粒度实验研究反馈信息量的影响；多轮对话实验比较反馈组织方式；四种策略实验分析提示词工程与反馈循环的关系。此外，建立了完整的实验产物管理和审计体系。

1.4 本文主要贡献

本文的贡献主要体现在三个层面。

在系统实现层面，构建了可复现的 AutoChip 风格 RTL 生成与修复原型系统，支持双 benchmark 接入、多模型调用、可配置的反馈粒度和提示词策略，以及完善的实验产物管理和审计机制。

在实验验证层面，引入 RTLLM_STUDY_12 作为核心实验子集，在更难 benchmark 和更强模型条件下验证了反馈循环的有效性。通过消融实验将反馈收益分解为多采样贡献和反馈信息贡献，并通过 4 轮独立重复验证了结论的统计稳定性。实验发现反馈效果具有模型依赖性：GPT-5.4 上反馈始终有效，Sonnet 上则不然。

在机制探索层面，系统研究了反馈粒度、多轮对话和提示词策略的影响，揭示了反馈信息量的倒 U 型边界——编译反馈和简洁反馈是最稳健的选择，过于丰富的反馈可能产生信息过载。

1.5 论文组织结构

本文共分六章。第 1 章为绪论，介绍研究背景、现状和本文工作。第 2 章为相关技术与研究基础，介绍 Verilog 与 RTL 设计基础、大语言模型代码生成机制、EDA 编译仿真流程和 AutoChip 方法。第 3 章为系统设计与实现，描述原型系统的架构和关键模块。第 4 章为实验设计，定义全部实验的方案和评价指标。第 5 章为实验结果与分析，呈现七组实验的结果并进行综合讨论。第 6 章为总结与展望，总结工作、讨论局限性并展望后续方向。



2 相关技术与研究基础

本章介绍与本文研究密切相关的技术基础和评估基准，包括 Verilog 与 RTL 设计基础、大语言模型代码生成机制、EDA 编译仿真流程、AutoChip 方法与反馈循环思想，以及本文使用的两个评估基准。本章的目的是为第 3 章的系统设计和第 4–5 章的实验分析建立必要的技术背景。

2.1 Verilog 与 RTL 设计基础

2.1.1 RTL 设计的基本概念

寄存器传输级（Register Transfer Level, RTL）是数字集成电路设计中最重要抽象层次之一。在 RTL 层面，设计者使用硬件描述语言描述数据在寄存器之间的传输和变换逻辑，这些描述随后通过综合工具转化为门级网表，最终映射到物理芯片。

Verilog 是工业界最广泛使用的硬件描述语言之一。一个 Verilog 设计的基本单元是模块（module），每个模块定义一组输入和输出端口，并在内部实现相应的硬件功能。模块内部的逻辑可分为两大类：组合逻辑（输出仅取决于当前输入，如加法器、多路选择器）和时序逻辑（输出还取决于过去的状态，如计数器、状态机）。有限状态机（FSM）是时序逻辑的典型代表，广泛应用于协议控制、序列检测等场景。

2.1.2 RTL 代码与软件代码的关键差异

RTL 代码的自动生成比普通软件代码生成更具挑战性，主要源于以下本质差异。在并行性方面，软件代码通常按顺序执行，而 Verilog 中的 always 块和 assign 语句在仿真语义下是并行执行的，生成代码时需要正确处理多个并发信号的时序关系。在时钟与复位方面，时序逻辑依赖时钟边沿触发和复位信号初始化，遗漏复位逻辑或错误的时钟边沿敏感列表会导致仿真行为与预期不一致。在硬件结构约束方面，每一行 Verilog 代码最终对应物理硬件，不当的描述可能导致综合后的电路行为异常。在位宽语义方面，信号的位宽需要精确匹配，符号扩展、截断、拼接等位操作的错误是 RTL 代码中常见的 bug 来源。

这些差异意味着，即使大语言模型在软件代码生成上表现良好，其生成的 RTL 代码仍可能包含硬件语义层面的错误，需要 EDA 工具进行验证。



2.2 大语言模型代码生成基础

2.2.1 基于提示词的代码生成

大语言模型 (Large Language Model, LLM) 通过在大规模文本和代码语料上的预训练, 获得了根据自然语言描述生成代码的能力 [8]。在代码生成任务中, 用户提供一段包含需求描述的提示词 (prompt), 模型基于其内部的概率分布逐 token 采样生成代码。

采样温度 (temperature) 是控制生成随机性的关键参数。较低的温度使模型倾向于选择概率最高的 token, 生成更确定性的输出; 较高的温度增加了输出的多样性, 有助于探索不同的解题路径。在本文的实验中, 温度统一设置为 0.7, 以平衡生成质量与多样性。

2.2.2 LLM 生成 RTL 代码的常见问题

尽管大语言模型具备一定的 Verilog 代码生成能力, 但在实际使用中常出现以下问题: 语法错误 (模块声明不完整、端口列表与描述不匹配、信号未声明等) 导致 EDA 编译失败; 接口不匹配 (生成的模块名称或端口定义与测试平台期望不一致) 导致编译时的模块实例化失败; 边界条件错误 (代码在大多数测试用例上正确但在特定边界条件上出错); 以及逻辑理解偏差 (模型对复杂算法的理解不够精确导致算法层面的实现错误)。

这些问题使得零样本生成通常难以覆盖复杂的 RTL 设计任务。这一现实为引入编译和仿真反馈来迭代修复代码提供了动机。

2.3 EDA 编译与仿真验证流程

2.3.1 编译验证

硬件设计的编译阶段将 Verilog 源代码解析为内部表示, 并检查语法正确性、信号声明一致性和模块接口匹配性。编译器输出的错误信息可以精确定位代码中的结构性问题。

本文使用 Icarus Verilog[9] (iverilog) 作为编译工具。iverilog 是一个开源的 Verilog 编译器和仿真器, 支持 IEEE 1364-2005 标准和部分 SystemVerilog 2012 特性 (通过 -g2012 选项启用)。选择开源工具的原因包括: 可免费获取, 适合本科毕设环境; 易于集成到自动化流程中; 实验结果完全可复现, 不依赖商业许可。



2.3.2 功能仿真

编译成功后, 使用 VVP 仿真引擎执行编译产生的仿真程序。仿真过程中, 测试平台 (testbench) 对待测设计施加激励信号, 并将设计输出与预期结果进行比较。

仿真结果通常以通过/失败的形式呈现。VerilogEval 的测试平台通过逐样本比较待测模块与参考模块的输出, 报告不匹配的样本数; RTLLM 的测试平台则直接输出 “Your Design Passed” 或失败统计。这些结构化的仿真输出为后续的反馈提供了可解析的信号。

2.3.3 编译仿真反馈的信号价值

编译和仿真的输出信息具有重要的反馈价值: 编译错误可以精确指出语法或接口层面的问题, 仿真失败则揭示逻辑层面的功能错误。将这些信息反馈给大语言模型, 使模型能够定向修复代码, 而非盲目重新生成。这一思想构成了 AutoChip 方法的核心。

2.4 AutoChip 方法与 EDA Feedback Loop

2.4.1 AutoChip 的核心思想

AutoChip[5] 提出了一种基于 EDA 工具反馈的 Verilog 代码迭代修复方法。其核心闭环为: 大语言模型根据自然语言描述生成 Verilog 代码, EDA 工具对代码进行编译和仿真验证, 验证结果中的错误信息被提取并组织为结构化反馈, 反馈与原始任务描述一起构成新的提示词, 模型据此生成修复后的代码。此过程反复迭代, 直到代码通过全部测试或达到最大迭代次数。

与传统的零样本生成相比, 这种 “生成—验证—反馈—修复” 闭环具有两方面优势: 一是能够利用 EDA 工具提供的精确错误定位信息; 二是通过多轮迭代逐步逼近正确解, 尤其适用于模型首次生成 “接近正确” 但存在局部错误的场景。

2.4.2 反馈信息的组织

反馈信息的组织方式对修复效果有影响。简洁反馈 (succinct feedback) 的基本思想是: 不直接将完整的编译日志或仿真波形传递给模型, 而是提取关键信息 (如错误行号、不匹配样本数、仿真输出摘要), 在控制 token 消耗的同时保留有效的修复线索。



2.4.3 多候选生成与全局最优追踪

在每轮迭代中，系统可生成多个候选代码（k-candidate generation），并从中选择最优候选。全局最优追踪机制确保反馈始终基于历史最佳代码的错误信息构建，避免因当前轮代码质量暂时回退而丢失历史最优解。

2.4.4 本文与 AutoChip 的关系

本文复现了 AutoChip 的核心闭环思想，并在以下维度进行了扩展：在 VerilogEval 和 RTLLM 两个 benchmark 上验证有效性；使用多个不同能力等级的大语言模型（Haiku、Sonnet、GPT-5.4）进行交叉验证；设计了 retry-only 消融条件以分离多采样与反馈信息的各自贡献。

此外，本文还通过稳定性重复实验验证结论的统计稳健性，并探索了反馈粒度、多轮对话反馈和初始提示词策略等多个优化方向。

2.5 RTL 生成评估基准

2.5.1 VerilogEval Benchmark

VerilogEval[3] 是 NVlabs 发布的 Verilog 代码生成评估基准，发表于 ICCAD 2023。其人工编写子集（VerilogEval-Human）包含 156 道来自 HDLBits[10] 的硬件设计任务，覆盖组合逻辑、时序逻辑、有限状态机等多种类型，难度从基础的线连接到复杂的 Conway 生命游戏。

VerilogEval 的评估方式为 spec-to-RTL：给定自然语言描述和模块接口定义，要求生成完整的模块实现。本文在中期阶段选取 VerilogEval-Human 的 20 道题目作为基线实验任务集。

2.5.2 RTLLM Benchmark

RTLLM[4] 是香港科技大学发布的 RTL 设计生成评估基准，发表于 ASP-DAC 2024。该基准包含 50 个涵盖算术运算、控制逻辑、存储器和杂项功能的硬件设计任务，难度从基础加法器到 IEEE 754 浮点乘法器、流水线乘法器和交通灯控制器等复杂设计。

与 VerilogEval 相比，RTLLM 的任务普遍更为复杂。本文在接入 RTLLM 前进行了全量 Icarus Verilog 兼容性审计：50 个设计中 46 个编译通过（92%），41 个仿真通过



(82%)。基于审计结果，本文从 41 个完全可用的设计中选取了 RTLLM_STUDY_12 正式研究子集。

2.6 相关研究与本文定位

2.6.1 相关研究方向

围绕大语言模型与硬件设计的交叉领域，已有研究主要覆盖以下方向：LLM 直接生成 RTL[1-2, 11]，RTL 生成评估方法 [3-4]，EDA 反馈与自修复 [5-7]，提示词工程 [8, 12]，以及多轮交互与代理方法 [13-14]。

2.6.2 本文定位

本文的定位是：构建一个可复现的 AutoChip 风格闭环系统，并在更强模型、更难 benchmark 上系统分析反馈循环的有效性、边界和影响因素。本文不以训练新模型或开发新的商业 EDA 工具为目标，而是聚焦于实验性贡献。

2.7 本章小结

本章介绍了本文研究所涉及的技术基础：Verilog 与 RTL 设计的基本概念及其与软件代码的差异，大语言模型生成代码的机制及其在 RTL 任务上的局限，EDA 编译与仿真验证的流程及其反馈信号价值，以及 AutoChip 方法的核心思想。同时介绍了本文使用的两个评估基准——VerilogEval-Human 和 RTLLM——及其在实验中的定位。这些技术基础为第 3 章的系统设计与实现奠定了背景。



3 系统设计与实现

本章介绍本文所构建的 AutoChip 风格 RTL 自动生成与反馈修复原型系统的总体架构、核心模块设计与关键实现细节。该系统以”生成—编译—仿真—反馈—修复”为核心闭环，支持多种 benchmark 接入、多模型切换、多种反馈策略与提示词策略，为后续实验提供了统一的可复现实验平台。

3.1 系统总体架构

3.1.1 设计目标

本系统的核心目标是构建一个可扩展、可审计的 AutoChip 风格实验平台 [5]，具体包括：接入多种公开 RTL benchmark，将不同格式的題目统一为内部 Task 表示；调用大语言模型生成 Verilog 代码，并通过 EDA 工具链进行编译与仿真验证；将验证结果以结构化反馈形式返回模型，驱动迭代修复；记录完整实验过程元数据，确保结果可追溯、可审计。

3.1.2 模块划分

系统由以下核心模块组成：任务加载器（Task Loader）负责从不同 benchmark 目录中读取题目描述、模块接口与测试平台文件，统一转化为内部 Task 数据结构；提示词构建器（Prompt Builder）根据任务描述、模块接口及可选的反馈信息，构建发送给大语言模型的提示词；大语言模型客户端（LLM Client）封装 API 调用逻辑，通过第三方统一网关接入多种模型；Verilog 提取器从模型返回的文本中提取代码块；Verilog 执行器调用 Icarus Verilog 编译器和 VVP 仿真器；评分器基于编译与仿真结果对候选代码打分；反馈循环控制器实现完整的迭代闭环；实验产物管理器负责元数据记录与结果序列化。

图3.1展示了系统的整体数据流：任务加载器从 benchmark 目录读取题目，提示词构建器将题目描述与反馈信息组织为提示词，LLM 客户端调用模型获得自然语言回复，Verilog 提取器从中提取代码，执行器进行编译与仿真，评分器给出分数，反馈循环控制器根据分数决定是否继续迭代。




图 3.1 AutoChip 风格 RTL 生成与反馈修复系统架构

3.2 任务加载与 Benchmark 接入

3.2.1 Task 数据结构

为了屏蔽不同 benchmark 在文件组织和题目格式上的差异，系统定义了统一的 Task 数据结构，包含四个核心字段：任务名称（name）、自然语言描述（description）、模块接口声明（module_header）以及测试平台文件路径（testbench_path）。

3.2.2 VerilogEval-Human 加载器

VerilogEval[3] 采用 spec-to-RTL 模式，提供自然语言描述和 TopModule 接口定义。VerilogEval 加载器的核心逻辑是：读取自然语言描述作为 description，读取接口声明作为 module_header，将参考实现与测试平台合并后写入临时文件作为 testbench_path。

3.2.3 RTLLM 加载器

RTLLM[4] 的每个题目目录包含一个自然语言设计描述文件和一个独立的测试平台文件。RTLLM 加载器通过递归遍历分类目录来发现所有题目，对每个包含 design_description.txt 和 testbench.v 的目录创建一个 RTLLMProblem 对象。



3.2.4 适配层的必要性

两个 benchmark 在文件结构、描述格式、测试平台组织和仿真输出格式上的差异，使得专用加载器成为必要。统一的 Task 接口确保了反馈循环控制器和评分器等下游模块无需关心数据来源。

3.3 大语言模型调用与模型管理

3.3.1 统一 API 网关架构

本系统通过第三方统一 API 网关接入多种大语言模型。网关的核心价值在于：保持 API 密钥和服务端点固定不变，仅通过模型名称参数切换不同的底层模型。

3.3.2 重试机制与错误分类

系统内置了指数退避重试机制：对可重试的瞬态错误自动重试最多 3 次，退避间隔为 2s、5s、10s。当所有重试均失败时，错误信息被封装为结构化的 APIError 对象，记录到该候选结果中。

3.3.3 对实验可追溯性的意义

上述设计确保了两个关键属性：任何实验结果都可以精确追溯到使用的模型名称和调用参数；API 错误不会污染实验数据。

3.4 Verilog 代码提取、编译与仿真执行

3.4.1 代码提取

Verilog 提取器首先移除 Markdown 代码围栏标记，然后使用正则表达式匹配所有 module ... endmodule 结构。该设计对 CoT 提示策略具有兼容性。

3.4.2 编译执行

编译阶段使用 Icarus Verilog[9] 将生成的设计代码与测试平台一起编译，启用-g2012 选项支持 SystemVerilog 2012 标准，并设置 30 秒超时保护。



3.4.3 仿真执行与结果解析

仿真阶段使用 VVP 执行编译产生的仿真二进制文件，设置 60 秒超时保护。解析器实现了双格式支持：VerilogEval 格式匹配 mismatched samples is N out of M 模式；RTLMM 格式匹配 Your Design Passed 或 Test completed with N/M failures。

3.4.4 评分机制

评分器基于 AutoChip 论文定义的排序规则，将编译与仿真结果映射为一个标量分数，如表3.1所示。

表 3.1 评分机制定义

情况	分数	含义
未提取到有效 Verilog	-2.0	代码提取失败
编译失败	-1.0	存在语法或结构错误
编译有警告但无仿真结果	-0.5	可能存在问题
编译成功但无仿真数据	0.0	无法评估正确性
仿真部分通过	0 ~ 1.0	(总样本 - 不匹配)/总样本
仿真完全通过	1.0	设计正确

3.5 反馈循环控制机制


反馈循环是本系统的核心，实现了 AutoChip 论文提出的”生成—验证—反馈—修复”迭代闭环。

3.5.1 单轮反馈循环

单轮反馈循环（Single-turn Feedback Loop）的执行流程如下：第 1 轮使用初始提示词生成 k 个候选代码，分别编译、仿真、评分，选出全局最优候选；第 2 轮及后续，将全局最优候选的代码和对应的编译/仿真错误信息组织为反馈提示词，再次生成 k 个候选。循环直到某候选通过（rank=1.0）或达到最大迭代次数（默认 5 轮）。

全局最优追踪机制确保了反馈循环具有单调性。

AutoChip 反馈循环逻辑流程图



注: 每轮生成 k 个候选 (本实验 k=3), 选 rank 最高者作为下一轮的基础

图 3.2 反馈循环控制流程



3.5.2 Zero-shot 作为退化形式

零样本模式可视为反馈循环的退化形式： $k = 1$ 、 $\text{max_iterations}=1$ 。这一设计使得零样本基线实验和反馈实验共享相同的代码路径，确保了实验条件的公平性。

3.5.3 Retry-only 模式

为了区分反馈循环中“多次重试”和“错误反馈信息”各自的贡献，系统实现了 **retry-only** 模式：在该模式下，所有迭代均使用初始提示词，不包含任何错误反馈信息。

3.5.4 API 错误处理

当某个候选的 API 调用失败时，该候选被标记为 `api_error` 但不终止整个迭代。只有当一轮迭代中所有 k 个候选全部因 API 错误而失败时，循环才提前终止。

3.6 反馈策略扩展实现

3.6.1 反馈粒度级别

为了研究反馈信息量对修复效果的影响，系统实现了三种反馈粒度级别：Level 2（Compile-only，仅编译反馈）仅反馈编译阶段的错误信息；Level 3（Succinct，简洁反馈）在编译反馈的基础上增加仿真失败时的不匹配样本数和仿真输出前 40 行，是系统的默认级别；Level 4（Rich，丰富反馈）进一步扩展仿真输出到前 80 行并添加显式分析提示。

结合 `loop_runner` 中零样本（Level 0）和 **retry-only**（Level 1），系统共支持五个梯度的反馈水平（L0-L4）。

3.6.2 多轮对话反馈

除单轮反馈外，系统还实现了多轮对话反馈模式（Multi-turn Feedback）。与单轮模式中每次 API 调用均为独立请求不同，多轮模式维护一个持续增长的对话历史。

多轮对话的关键设计考虑包括：初始消息使用简化版提示词；反馈消息不包含上一轮的代码（因为代码已存在于对话历史中）；反馈信息必须描述模型在对话中最后一轮生成的代码的错误，确保反馈与上下文一致。



3.7 提示词策略扩展实现

3.7.1 四种提示策略

为了研究初始提示词工程对 RTL 生成质量的影响，系统实现了四种可切换的提示策略 [8, 12]: P0 (Base Prompt, 直接指令式提示)、P1 (CoT Prompt, 思维链提示)、P2 (Few-shot Prompt, 少样本提示) 和 P3 (Few-shot + CoT Prompt)。

3.7.2 数据泄漏防护

Few-shot 示例的选择需要避免数据泄漏。系统使用的两个示例——8 位加法器和 4 位计数器——均不在正式实验使用的 STUDY_12 子集中。

3.7.3 策略调度机制

提示策略通过 PromptStrategy 枚举类型定义，由实验脚本通过命令行参数传入。策略选择被记录在实验元数据中，确保结果可追溯。

3.8 实验产物管理与审计机制

3.8.1 实验目录结构

系统采用类型化的实验产物目录结构。每个实验运行拥有唯一的 run_id，其目录下包含 summary.json、details.json 和 summary.csv 三类产物文件。

3.8.2 元数据与 Git 集成

每次实验运行的元数据自动采集当前 Git 仓库状态，包括 commit hash、分支名称和工作区是否有未提交的修改。

3.8.3 审计脚本

代码审计脚本 (audit_project.py) 执行 24 项自动化检查；数据审计脚本 (audit_data.py) 遍历所有实验运行目录，从原始 summary.json 中重新计算通过率，与文档记录的结论交叉验证。



3.8.4 权威实验索引

为防止论文撰写过程中误引用已废弃的实验结果，系统建立了权威实验索引文档，明确标注每个实验阶段的状态。

3.9 本章小结

本章详细介绍了 AutoChip 风格 RTL 自动生成与反馈修复原型系统的设计与实现。系统以统一的 Task 接口屏蔽了不同 benchmark 的格式差异，通过第三方统一 API 网关实现了多模型无缝切换，通过可配置的反馈粒度和提示词策略支持了多维度的实验对比。该系统为第 4 章的实验设计和第 5 章的实验分析提供了坚实的工程基础。



4 实验设计

本章定义本文全部实验的目标、评估基准、模型配置、实验条件、评价指标与可靠性控制方法。实验设置均来自真实的实验脚本与权威文档，具体结果将在第 5 章中呈现。

4.1 实验目标与总体设计

本文的实验围绕七个核心研究问题展开：EDA 反馈循环能否稳定提升 Verilog 代码正确性；反馈收益中多次重试与错误信息各自贡献多少；结论在多次独立重复下是否稳定；不同粒度的反馈对修复效果有何影响；多轮对话反馈是否优于单轮；初始提示词优化对生成质量的影响；以及上述结论在不同能力模型上是否一致。

为回答这些问题，本文设计了七组递进式实验，遵循从基础验证到深入分析的递进逻辑。第一层是有效性验证：先在 VerilogEval-Human 上完成基线实验确认系统可用性，再在更难的 RTLLM_STUDY_12 上进行三模型正式对比实验。第二层是因果归因：通过设计 retry-only 消融条件，将反馈循环的总收益分解为多采样贡献和反馈信息贡献两个独立来源，并通过每模型 4 轮的稳定性重复实验检验因果结论的统计可靠性。第三层是机制探索：通过反馈粒度、多轮对话和提示词策略三组实验，分别从信息量、信息组织方式和初始生成质量三个维度探索优化空间。表4.1给出了研究问题与实验设计的对应关系。

表 4.1 研究问题与实验设计对应关系

编号	研究问题	对应实验	主要比较条件
RQ1	反馈循环是否提升正确率	基线 + 正式实验	Zero-shot vs Feedback
RQ2	反馈 vs 多次重试的贡献	消融实验	Retry-only vs Feedback
RQ3	结论是否统计稳定	稳定性重复	4 轮独立重复
RQ4	反馈粒度的影响	粒度实验	L0-L4 五级
RQ5	多轮对话是否优于单轮	多轮对话实验	ST vs MT
RQ6	提示词策略的影响	策略实验	P0-P3 四种策略
RQ7	跨模型一致性	全部实验	三个模型交叉验证



4.2 评估基准与任务子集

VerilogEval-Human 20 题子集。 VerilogEval-Human[3] 是 NVlabs 发布的 Verilog 代码生成评估基准的人工编写子集。本文在中期阶段选取其中 20 个题目作为基线实验的任务集，覆盖组合逻辑、时序逻辑、有限状态机等多种类型。

RTLLM 基准与兼容性审计。 RTLLM 2.0[4] 包含 50 个硬件设计任务。由于本文使用 Icarus Verilog[9] 作为编译仿真工具，接入前进行了全量兼容性审计，结果如表4.2所示。

表 4.2 RTLLM 2.0 Icarus Verilog 兼容性审计结果

指标	数量	比例
总设计数	50	100%
编译通过	46	92%
仿真通过	41	82%
编译失败	4	8%
编译通过但仿真异常	5	10%

RTLLM_CORE_5 打通验证子集。 在正式实验前，本文定义了一个 5 题的最小验证子集 RTLLM_CORE_5 用于端到端验证。该子集的选取标准是：涵盖不同类别（算术、控制、存储器）、编译和仿真均已确认可用、难度适中。CORE_5 的实验结果仅用于确认系统在 RTLLM 格式下的正确运行，不作为正式结论来源。

RTLLM_STUDY_12 正式研究子集。 RTLLM_STUDY_12 是全部正式实验的核心任务集，包含 12 个精心选取的题目，如表4.3所示。选取标准包括：编译和仿真均通过兼容性审计；覆盖算术运算、控制逻辑、存储器和杂项功能四大类别；难度梯度从三星到五星，确保实验能够区分不同模型和条件的差异。其中 float_multi（IEEE 754 浮点乘法器）是整个 RTLLM 基准中难度最高的设计之一，sequence_detector 和 freq_divbyfrac 则在预实验中被发现对所有模型均构成挑战。

4.3 模型与参数设置

本系统通过第三方统一 API 网关接入多种大语言模型。实验涉及三个模型，代表三个能力等级，如表4.4所示。

除另有说明外，所有实验使用以下统一参数：temperature=0.7，max_tokens=4096，每轮候选数 $k = 3$ ，最大迭代轮数为 5，默认反馈级别为 L3 Succinct，默认提示策略为



表 4.3 RTLLM_STUDY_12 任务组成与类别分布

#	设计名	类别	难度
1	float_multi	Arithmetic/Other	★★★★★
2	multi_booth_8bit	Arithmetic/Multiplier	★★★★
3	multi_pipe_8bit	Arithmetic/Multiplier	★★★★
4	div_16bit	Arithmetic/Divider	★★★★
5	adder_bcd	Arithmetic/Adder	★★★
6	fsm	Control/FSM	★★★
7	sequence_detector	Control/FSM	★★★
8	JC_counter	Control/Counter	★★★
9	LIFObuffer	Memory/LIFO	★★★
10	LFSR	Memory/Shifter	★★★
11	traffic_light	Miscellaneous/Others	★★★★
12	freq_divbyfrac	Miscellaneous/Freq divider	★★★★

表 4.4 实验模型与角色说明

模型名称	提供商	角色	实验覆盖
claude-haiku-4-5	Anthropic	较弱基线	VerilogEval 基线 + RTLLM 正式
claude-sonnet-4-6	Anthropic	中强模型	正式 + 消融 + 稳定性 + 粒度 + 多轮
gpt-5.4	OpenAI	强模型	正式 + 消融 + 稳定性 + 粒度 + 多轮 + 策略



P0 Base。

4.4 实验条件与对照设计

正式实验。正式实验矩阵在 RTLLM_STUDY_12 上对三个模型分别运行两种条件：Zero-shot ($k=1$, 不迭代, 无反馈) 和 Feedback ($k=3$, 最多 5 轮, L3 Succinct 反馈) [5]。

消融实验。为分离多次重试与反馈信息的各自贡献, 设计了三条件消融：Zero-shot (预算 1)、Retry-only (预算最多 15, 无反馈) 和 Feedback (预算最多 15, L3 反馈)。

稳定性重复实验。对消融实验进行独立重复：GPT-5.4 和 Sonnet 4.6 各 4 轮, 每轮完全独立的 API 调用, 用于评估结论的统计稳健性。

反馈粒度实验。设计五级粒度条件：L0 Zero-shot、L1 Retry-only、L2 Compile-only、L3 Succinct、L4 Rich, 用于研究反馈信息量与修复效果的关系。

多轮对话反馈实验。设计四条件对照, 在 STUDY_12 的 6 题代表性子集 (Multiturn-6) 上运行。本实验初始版本 (v1) 存在代码 bug, 已修正为 v2 版本, 本文报告的所有多轮对话结果均来自 v2。

提示词策略实验 [8, 12]。设计四种提示策略 (P0 Base、P1 CoT、P2 Few-shot、P3 Few-shot+CoT) 的对比实验, 每种策略均运行 Zero-shot 和 Feedback 两种条件, 使用 GPT-5.4 模型。

4.5 评价指标与统计方法

通过率 (Pass Rate) 是本文的首要评价指标, 定义为通过测试平台全部测试用例的任务数占总任务数的比例。Rank 分数作为辅助指标, 取值范围为 $[-2.0, 1.0]$ 。派生指标包括 Feedback 改善题数 (衡量反馈的净贡献) 和 API 错误率 (衡量实验数据完整性)。

对于稳定性重复实验, 报告 4 轮重复的均值和标准差。对于单次运行的实验, 在结论表述中注明其局限性。

4.6 实验可靠性控制

审计与验证机制包括代码审计 (24 项检查) 和数据审计 (覆盖全部 7 个实验类别), 两项均已通过。权威实验索引明确标注每个实验阶段的状态, 确保论文中每一个实验数值均可追溯。



4.7 本章小结

本章定义了全部实验方案，涵盖两个评估基准、三个模型和七组递进式实验。各实验与研究问题的对应关系参见表4.1。

5 实验结果与分析

本章依次呈现七组实验的结果并进行分析。所有数据以权威实验索引为准。

5.1 VerilogEval-Human 基线实验

本节报告中期阶段在 VerilogEval-Human 20 题子集上使用 Haiku 模型的基线实验。反馈循环将通过率从 80% 提升至 90%，具体结果如表5.1所示。在 4 道零样本未通过的题目中，反馈成功修复了 2 道（50%）。

表 5.1 VerilogEval-Human 20 题基线实验结果

条件	通过数	通过率
Zero-shot	16/20	80%
Feedback	18/20	90%
提升	+2	+10 个百分点




图 5.1 VerilogEval-Human 20 题零样本与反馈通过率对比

反馈成功修复的两道题分别为 Prob109_fsm1 和 Prob127_lemmings1，均属于代码接近正确但存在局部状态转移错误的场景——反馈循环对这类“差一步”的问题尤为有效。未能修复的两道题分别涉及 LFSR 抽头多项式（精确数学知识）和 HDLC 协议边界条件



(深层协议逻辑)，表明反馈对领域知识缺口的修复能力有限。

5.2 RTLLM_STUDY_12 正式实验结果

在 RTLLM_STUDY_12 上使用三个模型进行 Zero-shot 与 Feedback 对比，结果如表5.2所示。三组实验的 API 错误率均为零。

表 5.2 RTLLM_STUDY_12 三模型正式实验结果

模型	Zero-shot	Feedback	提升	改善题数
Haiku 4.5	5/12 (42%)	6/12 (50%)	+8pp	2
Sonnet 4.6	5/12 (42%)	7/12 (58%)	+17pp	2
GPT-5.4	6/12 (50%)	10/12 (83%)	+33pp	4




图 5.2 RTLLM_STUDY_12 三模型通过率对比

反馈对所有模型均产生了正向增益。值得注意的是，强模型从反馈中获益最大——GPT-5.4 的增益（+33 个百分点）远超 Sonnet（+17 个百分点）和 Haiku（+8 个百分点），这说明并非弱模型最需要反馈，而是强模型最能利用反馈信息进行定向修复。

实验还发现了两类特殊题目：一是仅反馈可解的题目，如 LFSR 和 traffic_light 在零样本下所有模型均失败，仅在反馈条件下通过；二是天花板题，如 sequence_detector 和 freq_divbyfrac 在所有模型和条件下均未通过。




图 5.3 RTLLM_STUDY_12 逐题结果矩阵




图 5.4 各模型 Feedback 增益对比

5.3 Feedback vs Retry-only 消融实验

为区分反馈循环中”多次重试”与”错误反馈信息”的各自贡献，在 GPT-5.4 和 Sonnet 4.6 上运行了三条件消融实验（实验设计详见第 4 章）。

GPT-5.4 消融结果。 GPT-5.4 的单轮消融结果为：Zero-shot 50%（6/12），Retry-only 67%（8/12），Feedback 83%（10/12）。多采样贡献 +17 个百分点，反馈信息贡献 +16 个百分点，反馈信息约占总提升的 49%。需要注意的是，稳定性实验（4 轮均值，见 5.4 节）修正后的比例为反馈信息约占 57%。




图 5.5 零样本/重试/反馈三条件对比


消融实验中最具说服力的证据来自仅反馈可解的题目：sequence_detector 和 traffic_light 在 15 次独立重试中从未通过，但在反馈条件下于 2–3 轮内成功修复，直接说明错误反馈信息提供了独立采样无法获得的修复信号。

Sonnet 4.6 消融结果。 Sonnet 4.6 的单轮消融结果显示 Feedback（58%）低于 Retry-only（75%），但该结果受单轮随机波动影响较大，需结合稳定性实验综合判断。

5.4 稳定性重复实验

GPT-5.4。 4 轮独立重复中，Feedback 始终优于 Retry-only（4/4 轮），且无一例外。反馈不仅提升了平均通过率，还将标准差从 11.8%（零样本）压缩至 4.2%，如表 5.3 所示。

Sonnet 4.6。 Sonnet 上 Feedback（均值 58.3%±5.9%）低于 Retry-only（72.9%±3.6%）的结论在 4 轮中均成立（0/4 轮 FB 优于 RO），如表 5.4 所示。



sequence_detector & traffic_light: only solvable by feedback (15 retries all failed)

图 5.6 GPT-5.4 反馈收益来源分解

表 5.3 GPT-5.4 稳定性实验统计

统计量	Zero-shot	Retry-only	Feedback
均值	50.0%	62.5%	79.2%
标准差	$\pm 11.8\%$	$\pm 4.2\%$	$\pm 4.2\%$
FB>RO 轮次	—	—	4/4




图 5.7 稳定性实验三条件均值与标准差

表 5.4 Sonnet 4.6 稳定性实验统计

统计量	Zero-shot	Retry-only	Feedback
均值	62.5%	72.9%	58.3%
标准差	$\pm 7.2\%$	$\pm 3.6\%$	$\pm 5.9\%$
FB>RO 轮次	—	—	0/4




图 5.8 正式实验重复结果对比

模型依赖性。两个模型对反馈的响应截然相反：GPT-5.4 上 FB 相对 RO 的增益为 +16.7 个百分点，Sonnet 上为 -14.6 个百分点。这一分化在 4 轮重复中完全稳定，说明反馈机制的有效性具有显著的模型依赖性。

5.5 反馈粒度实验

五级粒度实验的通过率如表5.5所示。结果呈现出倒 U 型趋势：通过率随反馈信息量的增加先升后降，L2（Compile-only）和 L3（Succinct）达到峰值，而 L4（Rich）反而出现下降。

表 5.5 反馈粒度实验通过率

级别	GPT-5.4	Sonnet 4.6
L0 Zero-shot	58% (7/12)	50% (6/12)
L1 Retry-only	75% (9/12)	67% (8/12)
L2 Compile-only	92% (11/12)	75% (9/12)
L3 Succinct	92% (11/12)	67% (8/12)
L4 Rich	83% (10/12)	67% (8/12)

从实践角度看，L1→L2 是最大的跃升点，表明即使是最基础的编译错误反馈也具有极高的修复价值。L2 Compile-only 在两个模型上均为最优或并列最优，是最稳健的通用选择。




图 5.9 反馈粒度通过率曲线（倒 U 型）




图 5.10 反馈粒度逐题结果矩阵



5.6 多轮对话反馈实验

本节报告的结果均来自 v2 修正版。v1 版本因反馈数据源 bug 已标记为 Superseded。

GPT-5.4 和 Sonnet 4.6 的多轮对话实验结果分别如表5.6和表5.7所示。在控制候选数量的公平对比下 (ST $k=1$ vs MT $k=1$)，GPT-5.4 从 83% 提升至 100% (+17 个百分点)，Sonnet 4.6 从 33% 提升至 50% (+17 个百分点)，两个模型的提升幅度一致。这一结果表明，持续的对话上下文有助于模型理解修复历史和错误演变。需要注意的是，MT $k=1$ 与 ST $k=3$ 的比较 (如 Sonnet 上 50% vs 17%) 并不公平，因为候选数量不同，仅可作为参考。此外，该实验在 6 题子集上进行且为单次运行，结论需谨慎解读。

表 5.6 多轮对话反馈 v2 实验结果 (GPT-5.4)

条件	通过率
A: ST $k=3$	83% (5/6)
D: ST $k=1$	83% (5/6)
B: MT $k=1$	100% (5/5)*
C: CO $k=3$	83% (5/6)

*freq_divbyfrac 因 API 超时排除。

表 5.7 多轮对话反馈 v2 实验结果 (Sonnet 4.6)

条件	通过率
A: ST $k=3$	17% (1/6)
D: ST $k=1$	33% (2/6)
B: MT $k=1$	50% (3/6)
C: CO $k=3$	33% (2/6)

5.7 提示词策略实验

使用 GPT-5.4 在 STUDY_12 上对比四种提示策略，结果如表5.8所示。

在零样本阶段，Few-shot (P2) 以 67% 成为最优策略，CoT (P1) 反而略有负面影响。但引入反馈后，四种策略全部收敛至 92% (11/12)，仅 freq_divbyfrac 在所有策略下均未通过。这一“拉平效应”表明，反馈循环是代码质量的主导因素，初始提示词策略更多影响零样本起点而非最终上限。




图 5.11 多轮对话反馈 v2 条件对比




图 5.12 多轮对话反馈 v2 逐题矩阵



表 5.8 提示词策略实验结果 (GPT-5.4)

策略	Zero-shot	Feedback	FB 增益
P0: Base	58% (7/12)	92% (11/12)	+34pp
P1: CoT	50% (6/12)	92% (11/12)	+42pp
P2: Few-shot	67% (8/12)	92% (11/12)	+25pp
P3: Few-shot+CoT	58% (7/12)	92% (11/12)	+34pp




图 5.13 提示词策略零样本与反馈对比




图 5.14 提示词策略逐题结果矩阵



5.8 典型案例分析

float_multi: 反馈修复最高难度设计。 float_multi (IEEE 754 浮点乘法器) 是 STUDY_12 中难度最高的题目, 要求实现符号位处理、指数加法、尾数乘法和规格化等多个步骤。三个模型在零样本下全部失败, 典型的错误模式包括指数偏移计算错误和尾数乘积截断方式不正确。然而, Sonnet 和 GPT-5.4 均在反馈的第 1 轮迭代中成功修复——编译错误信息准确指出了语法问题, 仿真反馈则帮助模型定位了具体的数值计算偏差。Haiku 即使有反馈仍无法修复, 表明该题的修复需要模型具备一定的浮点运算先验知识, 反馈信息本身不足以弥补基础能力的差距。

LIFObuffer: 反馈弥补模型差距。 LIFObuffer (后进先出缓冲区) 展示了反馈机制的另一种价值。GPT-5.4 零样本即通过, 说明该题对强模型不构成挑战。但 Haiku 在零样本下生成的代码存在读写指针管理错误, 反馈循环在第 1 轮提供了仿真输出中的指针越界信息, Haiku 据此成功修复, 追平了 GPT-5.4 的零样本水平。这一案例说明反馈机制在资源受限场景下提供了“以计算换准确度”的可行路径——使用较弱但成本更低的模型配合反馈循环, 可以达到与强模型零样本相当的效果。

adder_bcd 与 div_16bit: 反馈的稳定收益。 adder_bcd (BCD 加法器) 和 div_16bit (16 位除法器) 是两道中等难度的算术题目。在正式实验中, 这两道题在多个模型上呈现出一致的规律: 零样本下编译通过但仿真部分失败, 反馈 1-2 轮后成功修复。仿真反馈中的不匹配样本数为模型提供了明确的修复方向, 这类“功能接近正确但存在边界错误”的场景是反馈循环最典型的应用场景。

天花板题分析。 sequence_detector 在正式实验中所有模型和条件均编译失败, freq_divbyfrac 在所有条件下均未通过仿真。对 sequence_detector 的错误日志分析表明, 模型生成的代码在模块接口上与测试平台不匹配, 且多轮反馈未能纠正这一结构性问题。然而, sequence_detector 在后续的消融稳定性实验和提示词策略实验中被成功修复, 说明该题并非绝对不可解, 而是对初始生成路径高度敏感——不同的随机种子或提示词可能导致截然不同的初始代码结构。freq_divbyfrac (分数分频器) 则涉及精确的小数分频算法, 属于当前框架难以仅通过反馈解决的领域知识缺口问题。

5.9 综合讨论

综合七组实验的结果, 可以从以下几个维度进行讨论。

在有效性方面, 反馈循环在 VerilogEval-Human 和 RTLLM_STUDY_12 两个 bench-



mark 上均表现出正向增益。GPT-5.4 在 RTLLM 上的增益达到 +33 个百分点，且在 4 轮重复中稳定存在 ($79.2\%\pm4.2\%$)。从实际应用角度看，这意味着在高难度设计任务上，引入反馈循环可以将强模型的通过率从约 50% 提升到约 80%，显著降低了人工干预的需求。

在收益来源方面，消融和稳定性实验揭示了反馈收益的双重来源：约 43% 来自多次采样机会，约 57% 来自错误反馈信息本身。后者的独立价值通过仅反馈可解的题目得到了直接验证——这些题目在 15 次独立重试中从未通过，但在 2–3 轮反馈后成功修复，说明反馈信息提供了采样无法替代的修复信号。

在模型依赖性方面，GPT-5.4 上反馈带来稳定的 +16.7 个百分点增益，而 Sonnet 4.6 上反馈反而导致 -14.6 个百分点的回退，两个结论均在 4 轮重复中完全稳定。这一发现具有重要的实践意义：在部署反馈循环系统时，不能假设反馈对所有模型都有效，需要针对具体模型进行验证。Sonnet 上反馈无效的可能原因包括：该模型可能对反馈信息中的噪声更敏感，或者其修复策略倾向于过度修改已正确的部分。

在信息量边界方面，粒度实验揭示了倒 U 型趋势，编译反馈 (L2) 是最稳健的通用选择。这一发现与信息论中的“信息过载”概念一致：过于丰富的仿真输出可能干扰模型对关键错误的定位，反而不如简洁的编译错误信息有效。多轮对话和提示词策略可作为补充优化方向，其中反馈循环将所有提示词策略拉平至 92%，说明反馈是最终代码质量的主导因素。

表5.9汇总了各实验的主要结论。

表 5.9 主要实验结论汇总

实验	关键对比	主要结论
基线实验	Zero-shot vs FB	通过率 80%→90%
正式实验	三模型对比	GPT-5.4 增益最大 (+33pp)
消融实验	FB vs Retry-only	反馈信息贡献 ~57%
稳定性	4 轮重复	GPT-5.4 结论稳定 (4/4)
粒度实验	L0–L4	倒 U 型，L2 最稳健
多轮对话	ST vs MT	MT 有优势，需扩大验证
策略实验	P0–P3	反馈拉平至 92%

局限性。 RTLLM_STUDY_12 为 12 题子集，虽然覆盖了四大类别和多个难度梯度，但不能完全代表所有类型的 RTL 设计任务。部分实验（多轮对话、提示词策略）为单次运



行或在小子集上进行，统计效力有限。Sonnet 上反馈无效的深层原因尚未完全明确，可能需要更细粒度的错误分析来回答。天花板题暴露了当前框架对涉及精确算法知识的设计任务的局限。此外，实验仅使用 Icarus Verilog 作为仿真工具，商业 EDA 工具可能提供更丰富的诊断信息。

5.10 本章小结

本章通过七组递进式实验验证了 AutoChip 风格反馈循环的有效性和边界条件。核心发现包括：反馈循环在两个 benchmark 上均有效且 GPT-5.4 上增益最大；反馈信息贡献约占总提升的 57%；反馈效果具有模型依赖性；反馈信息量存在倒 U 型边界；多轮对话和提示词策略为补充优化方向。



6 总结与展望

6.1 本文工作总结

本文围绕”基于 EDA 工具反馈的 LLM Verilog 生成与自动优化”这一问题，完成了系统构建、基准接入和实验验证三方面工作。

在系统方面，构建了一个 AutoChip 风格的 RTL 自动生成与反馈修复原型系统，实现了完整的”生成—编译—仿真—反馈—修复”闭环。系统支持 VerilogEval 和 RTLLM 双 benchmark 适配、多模型统一调用、可配置的反馈粒度和提示词策略，以及完善的实验产物管理机制。

在基准接入方面，对 RTLLM 2.0 全部 50 个设计进行了 Icarus Verilog 兼容性审计 (41/50 完全可用)，从中精选 12 道高难度、多类别覆盖的设计构成 RTLLM_STUDY_12 正式研究子集。

在实验方面，设计并执行了七组递进式实验，涵盖基线验证、正式对比、消融分析、稳定性验证、反馈粒度、多轮对话和提示词策略等维度。同时建立了包含元数据记录、数据审计和权威实验索引的实验管理体系。

6.2 主要实验结论

基于七组实验的结果，本文的核心发现可以概括为以下几点。

EDA 工具反馈能够提升 RTL 代码生成正确率。在 VerilogEval-Human 上，Haiku 模型的通过率从 80% 提升至 90%；在 RTLLM_STUDY_12 上，GPT-5.4 从 50% 提升至 83%，绝对提升达 33 个百分点。反馈的收益并非简单的多次重试：消融实验表明反馈信息本身贡献了约 57% 的提升，且存在仅反馈可解而 15 次独立重试均无法通过的题目。

反馈效果具有模型依赖性，GPT-5.4 上反馈始终优于 Retry-only (4/4 轮)，而 Sonnet 4.6 上反馈在当前设置下反而不如 Retry-only (0/4 轮)。反馈信息量存在最佳区间，粒度实验呈现倒 U 型趋势，编译反馈和简洁反馈是最稳健的选择。多轮对话反馈和提示词策略可作为补充优化方向。



6.3 系统局限性

本文的实验和系统存在以下局限。RTLLM_STUDY_12 包含 12 道精选题目，虽然覆盖四大类别和较高难度梯度，但不能代表所有类型的 RTL 设计任务。正式实验集中在三个模型上，其他模型的反馈响应模式尚未验证。当前系统的反馈信息主要基于仿真文本输出，缺少更精确的波形级定位。部分实验为局部探索，样本量较小，统计效力有限。

6.4 后续工作展望

后续工作可从以下方向展开。

在基准覆盖方面，可将实验范围从 RTLLM_STUDY_12 扩展到更大的任务子集乃至全量 RTLLM，并引入更多高难度 RTL 生成基准以验证结论的普适性。当前 12 题子集虽然覆盖了四大类别，但对某些特定领域（如通信协议、DSP 处理链）的覆盖不足，扩大任务范围有助于发现反馈机制在不同设计领域的差异化表现。

在模型覆盖方面，可纳入更多闭源和开源大语言模型进行对照。当前实验发现的模型依赖性现象（GPT-5.4 上反馈有效而 Sonnet 上无效）提示不同模型对反馈信息的处理机制可能存在本质差异。通过扩大模型覆盖范围，有望总结出哪些模型特性有利于反馈利用，并据此探索根据模型特性和错误类型动态选择反馈策略的自适应机制。

在反馈精度方面，当前系统的仿真反馈主要基于文本级的仿真输出摘要，未能利用波形级的信号差异信息。后续可引入信号级差异分析，将仿真反馈从“第 N 个样本不匹配”提升到“信号 X 在时刻 T 的期望值与实际值不一致”的精度，这种更精确的反馈有望进一步提升修复效率。

在知识增强方面，天花板题（如 `freq_divbyfrac`）暴露了当前框架的一个根本局限：当模型缺乏特定算法的先验知识时，仅靠反馈信息难以引导模型发现正确的实现方案。针对这一问题，可探索通过检索增强 [7]——在修复过程中检索相似的 Verilog 设计实现作为参考——来补充模型的领域知识。

在验证方法方面，可探索将形式化验证工具集成到反馈循环中。形式化工具能够提供反例（counterexample），即导致设计行为不符合规格的具体输入序列，这些反例可作为比仿真输出更精确的修复线索。



6.5 本章小结

本章总结了本文在系统实现和实验分析方面完成的工作，概括了主要结论，讨论了系统和实验的局限性，并从基准扩展、模型覆盖、反馈精细化、知识增强和形式化验证等方面展望了后续研究。



结论

本文构建了 AutoChip 风格的 RTL 自动生成与反馈修复原型系统，并通过七组递进式实验系统验证了 EDA 工具反馈循环的有效性和边界条件。

实验表明，反馈循环在 VerilogEval-Human 和 RTLLM_STUDY_12 两个 benchmark 上均能提升大语言模型生成 Verilog 代码的正确率。其中 GPT-5.4 在 RTLLM_STUDY_12 上的通过率从 50%（零样本）提升至 83%（反馈），增益最大且在 4 轮重复实验中稳定（ $79.2\% \pm 4.2\%$ ）。消融实验将反馈收益分解为多采样贡献（约 43%）和反馈信息贡献（约 57%），且存在仅反馈可解而多次独立重试均无法通过的设计题目。

实验同时揭示了反馈机制的边界：反馈效果具有模型依赖性；反馈信息量存在倒 U 型边界，编译反馈是最稳健的选择；天花板题暴露了当前框架对复杂算法生成的局限。多轮对话反馈和提示词策略可作为补充优化方向。

本文的工作为理解 EDA 工具反馈在大语言模型 RTL 自动生成中的作用提供了实证分析和工程参考。



致谢

本论文是在王锐老师的悉心指导下完成的。从毕业设计选题、研究方向确定到实验设计和论文写作，王老师始终给予了专业而耐心的指导。特别是在中期答辩时，王老师提出的“引入更强模型和更难 benchmark 来验证反馈机制有效性”的建议，为本文后中期的实验方向指明了路径，直接推动了 RTLLM 基准的引入和多模型交叉验证实验的开展。在此，谨向王锐老师致以最诚挚的感谢。

感谢北京航空航天大学计算机学院提供的本科毕业设计训练平台和学习环境，使我有机会在本科阶段接触到大语言模型与硬件设计交叉领域的前沿研究问题，并完成一项相对完整的实验性研究。

本文的研究工作得益于多个优秀的开源项目和学术资源。感谢 Icarus Verilog 项目提供的开源编译与仿真工具，使本文的自动化验证流程成为可能；感谢 NVlabs 的 VerilogEval 和香港科技大学的 RTLLM 项目提供了高质量的 RTL 生成评估基准；感谢 Python 生态和 GitHub 平台为项目开发和版本管理提供了便利。

在论文写作和代码调试过程中，合理使用了智能辅助工具进行资料整理、代码检查和表达润色，所有实验设计、实验执行和结论分析均由本人独立完成并经过严格的数据审计。

感谢在大学四年学习生活中给予我帮助和支持的同学和朋友们，与大家的交流和讨论让我受益良多。最后，感谢我的家人在求学过程中给予的理解、支持和鼓励，使我能够专注于学业和研究。



参考文献

- [1] CHANG K, WANG Y, REN H, et al. ChipGPT: How far are we from natural language hardware design[J]. arXiv preprint arXiv:2305.14019, 2023.
- [2] THAKUR S, AHMAD B, et al. Verigen: A large language model for Verilog code generation[C]//Proceedings of the Design Automation and Test in Europe Conference (DATE). Antwerp, Belgium: IEEE, 2023.
- [3] LIU M, PINCKNEY N, KHAILANY B, et al. VerilogEval: Evaluating large language models for Verilog code generation[C]//Proceedings of IEEE/ACM International Conference on Computer-Aided Design (ICCAD). San Francisco, CA: IEEE, 2023.
- [4] LU Y, LIU S, ZHANG Q, et al. RTLLM: An open-source benchmark for design RTL generation with large language model[C]//Proceedings of the Asia and South Pacific Design Automation Conference (ASP-DAC). Incheon, Korea: IEEE, 2024.
- [5] THAKUR S, AHMAD B, FAN Z, et al. AutoChip: Automating HDL generation using LLM feedback[C]//Proceedings of the ML for Systems Workshop at NeurIPS. New Orleans, LA: [s.n.], 2023.
- [6] TSAI Y D, LIU M, REN H. RTLFixer: Automatically fixing RTL syntax errors with large language models[J]. arXiv preprint arXiv:2311.16543, 2024.
- [7] YAO X, et al. HDLdebugger: Streamlining HDL debugging with large language models[J]. arXiv preprint arXiv:2403.11671, 2025.
- [8] BROWN T B, MANN B, RYDER N, et al. Language models are few-shot learners[C]//Advances in Neural Information Processing Systems (NeurIPS). Red Hook, NY: Curran Associates, Inc., 2020.
- [9] WILLIAMS S. Icarus Verilog[EB/OL]. 2024. <https://github.com/steveicarus/iverilog>.
- [10] HDLBits. HDLBits — Verilog practice[EB/OL]. 2024. <https://hdlbits.01xz.net/>.
- [11] LIU S, FANG W, LU Y, et al. RTLCoder: Fully open-source and efficient LLM-assisted RTL code generation technique[J]. IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems, 2024.
- [12] WEI J, WANG X, SCHUURMANS D, et al. Chain-of-thought prompting elicits rea-



- soning in large language models[C]//Advances in Neural Information Processing Systems (NeurIPS). Red Hook, NY: Curran Associates, Inc., 2022.
- [13] HO C T, KUO C L, KHAILANY B, et al. VerilogCoder: Autonomous Verilog coding agents with graph-based planning and abstract syntax tree (AST) tools[J]. arXiv preprint arXiv:2408.08927, 2024.
- [14] BLOCKLOVE J, GARG S, KARRI R, et al. Chip-chat: Challenges and opportunities in conversational hardware design[C]//Proceedings of the ML for Systems Workshop at NeurIPS. New Orleans, LA: [s.n.], 2023.
- [15] MENZA M U I, HASSOUN S. AIvriL: Ai-driven RTL generation with verification-in-the-loop[J]. arXiv preprint arXiv:2409.11411, 2024.
- [16] FAN R, CHEN Y, ZHAO J, et al. AutoBench: Automatic testbench generation and evaluation using LLMs for HDL design[C]//Proceedings of the ML for Systems Workshop at NeurIPS. Vancouver, Canada: [s.n.], 2024.
- [17] PINCKNEY N, LIU M, KHAILANY B, et al. Revisiting VerilogEval: Newer LLMs, in-context learning, and specification-to-RTL tasks[J]. arXiv preprint arXiv:2408.11053, 2024.



附录 A 实验配置与运行命令

本附录记录了本文实验使用的典型运行命令模板和关键配置。

A.1 正式实验运行命令

Zero-shot

```
python scripts/run_rtllm_subset.py \  
--model gpt-5.4 --subset study12 \  
--mode zero-shot
```

Feedback (default: k=3, iter=5, succinct)

```
python scripts/run_rtllm_subset.py \  
--model gpt-5.4 --subset study12 \  
--mode feedback
```

Ablation (zero-shot + retry-only + feedback)

```
python scripts/run_rtllm_subset.py \  
--model gpt-5.4 --subset study12 \  
--mode ablation
```

Granularity (L0-L4)

```
python scripts/run_rtllm_subset.py \  
--model gpt-5.4 --subset study12 \  
--mode granularity
```

Multiturn (ST/MT/CO conditions)

```
python scripts/run_rtllm_subset.py \  
--model gpt-5.4 --subset study12 \  
--mode multiturn
```



```
# Prompt strategy (P0-P3, ZS+FB each)
python scripts/run_rtllm_subset.py \
    --model gpt-5.4 --subset study12 \
    --mode prompt_strategy
```

A.2 环境配置

实验环境：Python 3.11，Icarus Verilog 12.0，Ubuntu 22.04。API 通过第三方统一网关接入。

A.3 核心代码模块索引

表 A.1 系统核心代码模块索引

模块	文件路径
反馈循环控制器	src/feedback/loop_runner.py
提示词构建器	src/feedback/prompt_builder.py
Verilog 执行器	src/runner/verilog_executor.py
评分器	src/ranking/ranker.py
RTLLM 加载器	src/runner/rtllm_loader.py
VerilogEval 加载器	src/runner/verilogeval_loader.py
LLM 客户端	src/llm/client.py
Verilog 提取器	src/utils/extract_verilog.py
实验产物管理	src/utils/artifacts.py
代码审计	scripts/audit_project.py
数据审计	scripts/audit_data.py